Bases de datos relacionales
Plantilla de la primera entrega del proyecto de curso

Diseño y Configuración del Sistema RAG

Integrantes del grupo: Yeferson Castro Giraldo

Título del proyecto: **Archivo Histórico de Estética, Moda y Cultura Visual**

Fecha de entrega: 19-04-2026

Repositorio / URL del proyecto:

github:https://github.com/YefCastro/Archivo-Hist-rico-de-Est-tica-Moda-y-Cultura-Visual-.git

supabase: https://jxhyhzoglxtwpdtxtvkd.supabase.co

SECCION 1: UNIVERSO DEL DISCURSO Y ANALISIS DE REQUERIMIENTOS

Universo del discurso: El sistema gestionará un archivo digital enfocado en la evolución de la estética, la moda y la cultura visual. El sistema gestionará un archivo digital enfocado en la evolución de la estética, la moda y la cultura visual. Permitirá a investigadores y estudiantes (usuarios del sistema) almacenar y recuperar artículos analíticos (texto) y material visual (fotografías o ilustraciones), facilitando la búsqueda de relaciones semánticas entre corrientes estéticas, su impacto social y sus representaciones visuales a través del tiempo.

Los usuarios podrán realizar consultas que combinan filtros estructurados (como fechas, idioma o etiquetas) con búsquedas semánticas basadas en embeddings, permitiendo recuperar información relevante tanto en texto como en imágenes mediante un enfoque multimodal.

Tipos de Datos Involucrados

Enumere todos los tipos de datos que el sistema procesara. La columna 'Requiere vectorización' es para los campos que se vectorizaran. Marque Si solo si ese dato será insumo para búsqueda semántica.

Tipo de dato	Ejemplos concretos	Naturaleza (estructurado / no estructurado)	Requiere vectorización
Cadenas de texto cortas	Título del artículo, autor, idioma, etiquetas de imagen	Estructurado	No
Fechas	Fecha de publicación del documento, fecha de la consulta	Estructurado	No
Texto extenso	Contenido completo de ensayos sociológicos y críticas estéticas	No estructurado	**Sí**
Archivos Binarios (Imágenes)	Fotografías de prendas, portadas de revistas, ilustraciones	No estructurado	**Sí**
Vectores (Embeddings)	Representación matemática del texto y de las imágenes	Estructurado (representación numérica)	No (son el resultado de la vectorización)

Especificación de Requerimientos

Requerimientos Funcionales	Requerimientos No Funcionales
RF-01: El sistema debe almacenar documentos de texto e imágenes asociadas a corrientes estéticas y culturales.	**RNF-01:** Las consultas vectoriales deben ejecutarse utilizando índices optimizados (ej. HNSW o IVFFlat) en pgvector.
RF-02: El sistema debe permitir dividir el texto de los documentos utilizando al menos dos estrategias de *chunking* diferentes.	**RNF-02:** El LLM utilizado para la generación de la respuesta final debe ser accesible mediante una API gratuita con baja latencia.
RF-03: El sistema debe ejecutar búsquedas semánticas híbridas combinando filtros exactos (ej. fecha, idioma, etiquetas) con similitud de embeddings, permitiendo consultas texto-texto e imagen-texto mediante un enfoque multimodal.	**RNF-03:** El sistema debe implementar evaluación automática utilizando las métricas de *Faithfulness*, *Answer Relevancy* y *Context Recall* de RAGAS.

SECCION 2: DISENO CONCEPTUAL (ERD)

Complete la tabla para cada entidad del modelo. La columna 'Atributos principales' debe marcar con asterisco (*) los identificadores. La columna 'Cardinalidad' debe expresar la relación con otra entidad de forma explícita, por ejemplo: documentos 1 — N chunks.

Entidad	**Atributos principales (indique PK con *)**	**Relaciones (con qué otras entidades)**	**Cardinalidad**
USUARIO	id_usuario*, nombre, email, rol	Realiza CONSULTA	Usuario 1 — N Consulta
CONSULTA	id_consulta*, texto_pregunta, fecha	Realizada por USUARIO Produce RESULTADO Evalúa EVALUACION	Consulta N — 1 Usuario Consulta 1 — N Resultado Consulta 1 — 1 Evaluacion

		Vectoriza QUERY_EMBEDDING	Consulta 1 — 1 Query_Embedding
DOCUMENTO	id_doc*, titulo, idioma, fecha, fuente, contenido_texto	Contiene IMAGEN Fragmenta EMBEDDING_TEXTO Se asocia en RESULTADO_DOCUMENTO	Documento 1 — N Imagen Documento 1 — N Embedding_Texto Documento 1 — N Resultado_Documento
IMAGEN	id_img*, ruta_archivo, descripcion, etiquetas	Pertenece a DOCUMENTO Genera EMBEDDING_IMAGEN Se asocia en RESULTADO_IMAGEN	Imagen N — 1 Documento Imagen 1 — N Embedding_Imagen Imagen 1 — N Resultado_Imagen

EVALUACION	id_eval*, faithfulness, answer_relevancy, context_recall, modelo_eval, fecha	Evalúa CONSULTA	Evaluacion 1 — 1 Consulta
QUERY_EMBEDDING	id_qemb*, vector_embedding, modelo	Vectoriza CONSULTA	Query_Embedding 1 — 1 Consulta
EMBEDDING_TEXTO	id_embedding*, chunk_id, estrategia_chunking, vector_embedding, modelo	Fragmenta DOCUMENTO	Embedding_Texto N — 1 Documento
EMBEDDING_IMAGEN	id_embedding*, vector_embedding, modelo	Generada por IMAGEN	Embedding_Imagen N — 1 Imagen
RESULTADO	id_resultado*, score_similitud	Producido por CONSULTA	Resultado N — 1 Consulta Resultado 1 — N Resultado_Documento

		Se asocia en RESULTADO_DOCUMENTO Se asocia en RESULTADO_IMAGEN	Resultado 1 — N Resultado_Imagen
RESULTADO_DOCUMENTO	id_resultado*, id_doc*	Vincula RESULTADO y DOCUMENTO	Resultado_Documento N — 1 Resultado Resultado_Documento N — 1 Documento
RESULTADO_IMAGEN	id_resultado*, id_img*	Vincula RESULTADO e IMAGEN	Resultado_Imagen N — 1 Resultado Resultado_Imagen N — 1 Imagen

Diagrama Entidad-Relacion (ERD)

Inserte aquí el diagrama ERD del sistema. Puede pegarlo como imagen o describir la estructura si el diagrama se entrega en archivo separado. Si se entrega por separado, indique el nombre del archivo y asegúrese de que sea accesible desde el repositorio del proyecto.

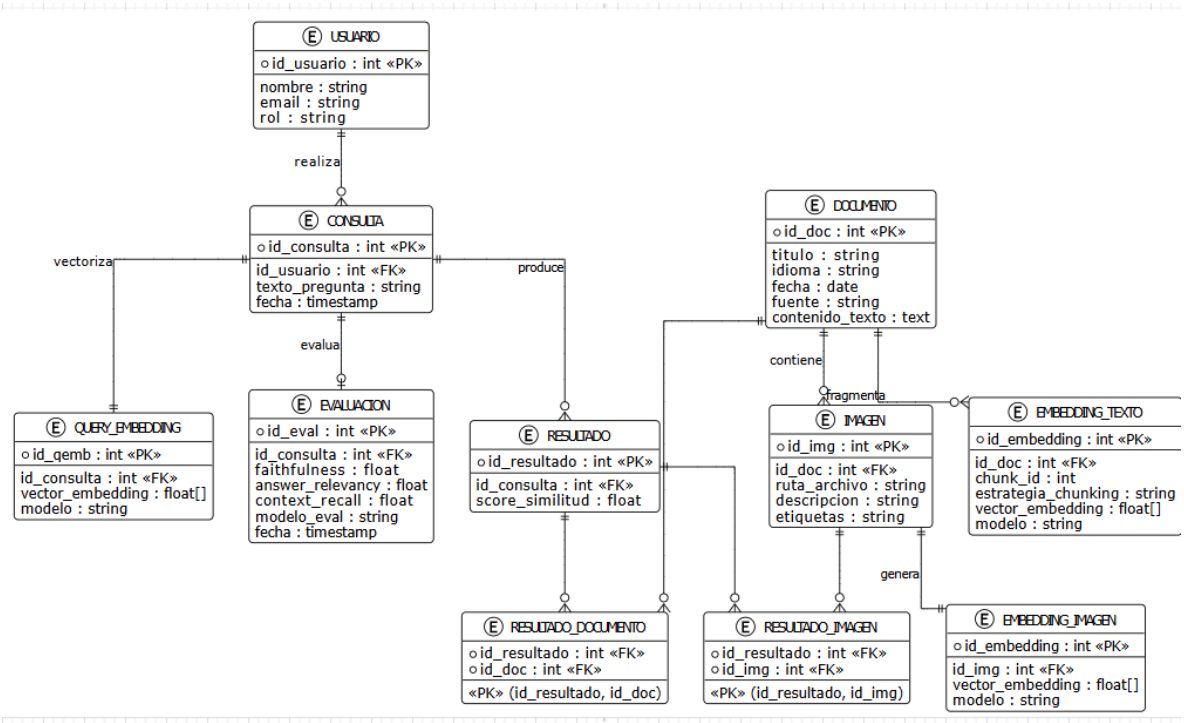

SECCION 3: DISEÑO LOGICO EN TERCERA FORMA NORMAL (3FN)

Tablas del Modelo Relacional

Complete la tabla para cada relación del modelo lógico. La columna 'Observaciones de normalización' debe indicar si hubo alguna descomposición o ajuste al pasar del modelo conceptual al lógico, y por que.

Tabla	Columnas	PK	FK(s)	Observaciones de normalización
USUARIO	id_usuario, nombre, email, rol	id_usuario	Ninguna	En 3FN. Los datos del usuario dependen únicamente de su ID.
DOCUMENTO	id_doc, titulo, idioma, fecha, fuente, contenido_texto	id_doc	Ninguna	En 3FN. Se mantiene el contenido de texto para facilitar el proceso de chunking.
IMAGEN	id_img, id_doc, ruta_archivo, descripcion, etiquetas	id_img	id_doc	En 3FN. Depende de DOCUMENTO para mantener la relación de origen.
CONSULTA	id_consulta, id_usuario,	id_consulta	id_usuario	En 3FN. Separa la interacción del

	texto_pregunta, fecha			usuario de los resultados técnicos.
RESULTADO	id_resultado, id_consulta, score_similitud	id_resultado	id_consulta	En 3FN. Actúa como cabecera para los conjuntos de documentos e imágenes recuperados.
EVALUACION	id_eval, id_consulta, faithfulness, answer_relevancy, context_recall, modelo_eval, fecha	id_eval	id_consulta	En 3FN. Almacena métricas RAGAS calculadas por cada consulta específica.
EMBEDDING_TEXTO	id_embedding, id_doc, chunk_id, estrategia_chunking, vector_embedding, modelo	id_embedding	id_doc	En 3FN. Descompuesta de Documento para permitir múltiples fragmentos (chunks) por archivo.
EMBEDDING_IMAGEN	id_embedding, id_img, vector_embedding, modelo	id_embedding	id_img	En 3FN. Almacena el vector generado por modelos como CLIP para cada imagen.

QUERY_EMBEDDING	id_qemb, id_consulta, vector_embedding, modelo	id_qemb	id_consulta	En 3FN. Representación vectorial de la pregunta del usuario.
RESULTADO_DOC	id_resultado, id_doc	(id_resultado, id_doc)	id_resultado, id_doc	**Normalización**: Se creó como tabla puente para resolver la relación N:N entre resultados y documentos.
RESULTADO_IMG	id_resultado, id_img	(id_resultado, id_img)	id_resultado, id_img	**Normalización**: Se creó como tabla puente para resolver la relación N:N entre resultados e imágenes.

Dependencias Funcionales Relevantes

Enfóquese en aquellas que determinaron decisiones de normalización: atributos que dependían parcialmente de la clave, o de otro atributo no clave.

Dependencias funcionales identificadas (use notacion: A → B):

- **USUARIO**: `id_usuario → nombre, email, rol`
- **DOCUMENTO**: `id_doc → titulo, idioma, fecha, fuente, contenido_texto`
- **IMAGEN**: `id_img → id_doc, ruta_archivo, descripcion, etiquetas`
- **CONSULTA**: `id_consulta → id_usuario, texto_pregunta, fecha`
- **EMBEDDING_TEXTO**: `id_embedding → id_doc, chunk_id, estrategia_chunking, vector_embedding` (El `chunk_id` depende de la combinación de documento y estrategia).

Verificación de Formas Normales

Para cada relación, indique en que forma normal se encuentra y si aún no está en 3FN indique que hizo para que cumpla la 3FN.

- **1FN**: Todos los atributos son atómicos (especialmente los vectores, que se manejan como un tipo de dato único `VECTOR`).
- **2FN**: No existen dependencias parciales; todos los campos que no son clave dependen totalmente de la clave primaria. Esto es evidente en las tablas puente (`RESULTADO_DOC` y `RESULTADO_IMG`) donde cada registro es una asociación única.
- **3FN**: Se eliminaron dependencias transitivas. Por ejemplo, los puntajes de evaluación dependen de la consulta, no del usuario que la hizo.

Notación del Modelo Lógico

Exprese el modelo lógico usando notación de esquema relacional: NombreTabla(campo1, *PK, campo2, #FK_OtraTabla). Liste todas las tablas.

- **Usuarios** (id_usuario*, nombre, email, rol)
- **Documentos** (id_doc*, titulo, idioma, fecha, fuente, contenido_texto)
- **Imagenes** (id_img*, #id_doc, ruta_archivo, descripcion, etiquetas)
- **Consultas** (id_consulta*, #id_usuario, texto_pregunta, fecha)
- **Resultados** (id_resultado*, #id_consulta, score_similitud)
- **Evaluaciones** (id_eval*, #id_consulta, faithfulness, answer_relevancy, context_recall, modelo_eval, fecha)
- **Embeddings_Texto** (id_embedding*, #id_doc, chunk_id, estrategia_chunking, vector_embedding, modelo)
- **Embeddings_Imagen** (id_embedding*, #id_img, vector_embedding, modelo)
- **Query_Embeddings** (id_qemb*, #id_consulta, vector_embedding, modelo)
- **Resultado_Documento** (id_resultado*, id_doc*)
- **Resultado_Imagen** (id_resultado*, id_img*)

SECCION 4: IDENTIFICACION DE CAMPOS VECTORIZABLES

Tabla de Campos Vectorizables

Complete una fila por cada campo que se vectorizara. La columna 'Modalidad' debe indicar 'texto' o 'imagen'. La columna 'Justificación' debe explicar por que ese campo aporta valor semántico recuperable, no simplemente que el campo existe.

Tabla	Campo	Tipo de dato SQL	Modalidad	Se vectoriza	Justificación
Documento	contenido_texto	TEXT	Texto	**Sí**	Permite extraer el conocimiento semántico sobre estética y cultura visual para alimentar el contexto del LLM.
Imagen	ruta_archivo	VARCHAR	Imagen	**Sí**	Permite realizar búsquedas multimodales (encontrar imágenes a partir de texto) mediante embeddings generados por CLIP.

Consulta	texto_pregunta	TEXT	Texto	**Sí**	La pregunta del usuario debe transformarse al mismo espacio vectorial que los documentos para calcular la similitud.

Script SQL de Creación de Tablas Base

Incluya el script SQL completo para crear las tablas relacionales del sistema. El script debe ser ejecutable en PostgreSQL, incluir tipos de datos correctos, restricciones NOT NULL, PRIMARY KEY y FOREIGN KEY donde corresponda.

```
CREATE EXTENSION IF NOT EXISTS vector;



CREATE TABLE Usuario (
    id_usuario SERIAL PRIMARY KEY,
    nombre VARCHAR(100) NOT NULL,
    email VARCHAR(150) UNIQUE NOT NULL,
    rol VARCHAR(50)
);

CREATE TABLE Documento (
    id_doc SERIAL PRIMARY KEY,
    titulo VARCHAR(255) NOT NULL,
    idioma VARCHAR(20),
    fecha DATE,
```

```sql
    fuente VARCHAR(255),
    contenido_texto TEXT NOT NULL
);

CREATE TABLE Imagen (
    id_img SERIAL PRIMARY KEY,
    id_doc INT REFERENCES Documento(id_doc) ON DELETE CASCADE,
    ruta_archivo VARCHAR(500) NOT NULL,
    descripcion TEXT,
    etiquetas VARCHAR(255)
);

CREATE TABLE Consulta (
    id_consulta SERIAL PRIMARY KEY,
    id_usuario INT REFERENCES Usuario(id_usuario) ON DELETE SET NULL,
    texto_pregunta TEXT NOT NULL,
    fecha TIMESTAMP WITH TIME ZONE DEFAULT CURRENT_TIMESTAMP
);

CREATE TABLE Resultado (
    id_resultado SERIAL PRIMARY KEY,
    id_consulta INT REFERENCES Consulta(id_consulta) ON DELETE CASCADE,
    score_similitud FLOAT
);

CREATE TABLE Resultado_Documento (
    id_resultado INT REFERENCES Resultado(id_resultado) ON DELETE CASCADE,
    id_doc INT REFERENCES Documento(id_doc) ON DELETE CASCADE,
```

```
    PRIMARY KEY (id_resultado, id_doc)
);


CREATE TABLE Resultado_Imagen (
    id_resultado INT REFERENCES Resultado(id_resultado) ON DELETE CASCADE,
    id_img INT REFERENCES Imagen(id_img) ON DELETE CASCADE,
    PRIMARY KEY (id_resultado, id_img)
);


CREATE TABLE Evaluacion (
    id_eval SERIAL PRIMARY KEY,
      id_consulta INT UNIQUE REFERENCES Consulta(id_consulta) ON DELETE
CASCADE,
    faithfulness FLOAT,
    answer_relevancy FLOAT,
    context_recall FLOAT,
    modelo_eval VARCHAR(100),
    fecha TIMESTAMP WITH TIME ZONE DEFAULT CURRENT_TIMESTAMP
);
```

Script SQL de Tablas Vectoriales

Defina las tablas que almacenaran los embeddings usando el tipo vector de pgvector. Especifique la dimensión del vector según el modelo de embeddings elegido en la Seccion 4. Incluya los índices vectoriales para búsqueda por similitud.

```
CREATE TABLE Embedding_Texto (
    id_embedding SERIAL PRIMARY KEY,
    id_doc INT REFERENCES Documento(id_doc) ON DELETE CASCADE,
    chunk_id INT NOT NULL,
```

```
    estrategia_chunking VARCHAR(50),
            vector_embedding vector(384), -- Dimensión estándar para all-MiniLM-L6-v2
    modelo VARCHAR(100)
);

CREATE TABLE Embedding_Imagen (
    id_embedding SERIAL PRIMARY KEY,
    id_img INT REFERENCES Imagen(id_img) ON DELETE CASCADE,
    vector_embedding vector(512), -- Dimensión estándar para CLIP
    modelo VARCHAR(100)
);

CREATE TABLE Query_Embedding (
    id_qemb SERIAL PRIMARY KEY,
      id_consulta INT UNIQUE REFERENCES Consulta(id_consulta) ON DELETE CASCADE,
    vector_embedding vector(384),
    modelo VARCHAR(100)
);

CREATE INDEX ON Embedding_Texto USING hnsw (vector_embedding vector_cosine_ops);
CREATE INDEX ON Embedding_Imagen USING hnsw (vector_embedding vector_cosine_ops);
```

SECCION 5: PLAN DE EXPERIMENTO DE CHUNKING

Marco Conceptual e Hipótesis

Antes de definir las estrategias, explique: (a) por que el chunking afecta la calidad del sistema RAG, (b) que hipótesis tiene sobre cual estrategia funcionara mejor para su tipo de contenido y (c) en que se basa esa hipótesis.

(a) ¿Por qué el chunking afecta la calidad del sistema RAG?: El *chunking* es una decisión crítica porque determina la unidad mínima de información que el sistema puede "entender" y recuperar. Si los fragmentos son demasiado pequeños, el modelo pierde el contexto necesario para responder preguntas complejas (fragmentación semántica). Si son demasiado grandes, se introduce "ruido" o información irrelevante que diluye la respuesta del LLM y puede exceder su ventana de contexto.

(b) Hipótesis sobre la mejor estrategia: Se proyecta que el Semantic Chunking (Segmentación Semántica) obtendrá los mejores resultados en las métricas de *Faithfulness* y *Answer Relevancy*.

(c) Base de la hipótesis: Dado que el contenido del proyecto trata sobre juicios de valor y razonamiento lógico (la influencia estética de Barbie), la información no es puramente factual ni está estructurada de forma uniforme. El *chunking* semántico agrupa oraciones basándose en la similitud de su significado, lo que garantiza que un argumento sobre estereotipos o una referencia teórica a la película se mantenga como una unidad lógica completa antes de ser vectorizada.

Estrategias y Parámetros de Chunking

Defina mínimo dos estrategias con sus parámetros exactos. La justificación técnica debe vincular la estrategia con las características del contenido descrito anteriormente, no ser una descripción genérica del método.

Estrategia	Tamaño chunk (tokens)	Overlap (tokens)	Separador / Criterio de corte	Justificación técnica

Estrategia A: Fixed-size chunking	256	32	Espacio / Carácter	Se establece como línea base (baseline) para evaluar la eficacia de una división simple. El solapamiento (overlap) busca evitar que términos clave sobre "estética" o "sociedad" queden cortados justo a la mitad entre dos fragmentos.
Estrategia B: Semantic chunking	Variable	N/A	Umbral de similitud coseno (0.82)	Ideal para textos sobre teoría estética donde los párrafos tienen longitudes desiguales. Al usar el umbral de 0.82, el sistema solo crea un nuevo fragmento cuando el tema cambia significativamente, preservando la cohesión de los argumentos sobre estereotipos de género.